ChargeWise AI — evolução da Sprint 4

Curso: Ciência da Computação | **Turma:** 2º semestre (2SEM), 2026.2

Disciplina: Prompt and Artificial Intelligence | **Parceiro:** GoodWe Brasil | **Data:** 23/10/2026

Resumo

A Sprint 4 converteu a base fixa em um fluxo RAG persistente e adicionou uma interface Streamlit. O corpus disponível é um cenário condominial simulado; não contém manuais ou especificações oficiais GoodWe. A aplicação recupera trechos, pede ao modelo seleção de citações literais, verifica cada citação e mostra documento e seção. Perguntas sem evidência ou de segurança recebem recusa. O índice Chroma contém 11 chunks, gerados com divisão de 900 caracteres e overlap de 135, usando nomic-embed-text.

Pipeline e decisões

Documentos Markdown com manifesto de origem → loader → limpeza e chunking → embeddings Ollama → Chroma persistente → retriever top-k → filtro por assunto → prompt RAG v3 → seleção JSON pelo modelo → validação literal das evidências → resposta e fontes na interface. O contexto recuperado é tratado como dado não confiável. O índice é reconstruído explicitamente quando o corpus ou embeddings mudam; credenciais e índice local não são versionados.

Antes e depois

Eixo	Antes: Sprint 3	Depois: Sprint 4	Evidência
Conhecimento	Contexto condominial inserido diretamente no prompt	Corpus rastreável e índice Chroma persistente	Manifesto, 11 chunks, fingerprint do índice
Resposta	Saída estruturada conversacional, sem citação de trecho	Seleção de citação literal validada, documento e seção visíveis	Serviço RAG e interface Streamlit
Avaliação	Intenção, schema, memória e guardrails	Recuperação, fidelidade, relevância, citação e recusas em 12 casos	evals/relatorio_rag.md e snapshots brutos
Relevância RAG	Sem score comparável	0,688 no baseline v1/k1 → 1,000 na configuração final v3/k3 com filtro	Rubrica manual assistida, 8 perguntas respondíveis
Segurança	Guardrails de entrada e moderação	Guardrails mais recusa sem evidência e teste isolado de injeção em documento	4/4 recusas fixas; 1 fixture de injeção resistida

Os scores conversacionais legados e os scores RAG usam datasets e rubricas diferentes; não representam ganho numérico entre sprints. O ganho RAG de relevância pertence às iterações internas da Sprint 4. O primeiro aumento isolado de prompt foi de 0,688 para 0,813 (v2 → v3); o filtro do pipeline levou a 1,000.

Comparação de modelos no RAG

Em 23/10/2026, qwen2.5:1.5b e llama3.2:latest foram chamados no Ollama local, em sequência, com o mesmo dataset de 12 casos, índice, prompt v3, k=3, temperature=0, top_p=0,9 e max_tokens=500. A revisão assistida por Codex deu relevância 1,000 ao Qwen e 0,875 ao Llama (8 casos com resposta esperada). Ambos tiveram recall estrito 0,500, fidelidade e citação 1,000 nas respostas emitidas, e 4/4 recusas corretas. O Llama recusou indevidamente a pergunta ambígua sobre a potência do equipamento pessoal; a média de 7 kW do cenário poderia ter sido informada com ressalva. Latência média ponta a ponta: 58,95 s e 62,57 s, respectivamente, em CPU local; a primeira chamada do Llama levou 246,16 s. Uma rodada por modelo não estabelece desempenho geral. O comparativo conversacional legado usa outro dataset e permanece separado em docs/relatorio_modelos.md.

Problemas e soluções

1. **Recuperação parcialmente imprecisa:** a busca top-k=3 encontrou apenas metade dos trechos exatos esperados. FAQ equivalente às vezes sustentou resposta correta sem contar como acerto estrito. O prompt v3 e o filtro por assunto corrigiram respostas fora do tópico, mas o recall de evidência exata permanece 0,500.

2. **Instrução maliciosa em documento:** texto recuperado tentava revelar o prompt. O serviço delimita o contexto, descarta citações que contenham comandos e exige substring literal e chunk_id válido. O fixture isolado foi respondido com a política de reserva sem revelar instruções internas.

3. **Cobertura limitada:** não foram obtidos manuais oficiais GoodWe para o corpus. O produto identifica o cenário como simulado e recusa especificações de modelo e telemetria em tempo real.

Limitações e próximos passos

A avaliação 0/0,5/1 foi assistida por Codex sobre amostra pequena, sem RAGAS ou revisão humana independente. O limiar de distância 1,0 ainda não foi calibrado. As respostas literais podem ser menos naturais que uma síntese, mas permitem verificar suporte e citação. O índice depende de Ollama local em operação; o tempo de CPU e disponibilidade de modelos variam. Para ampliar o escopo, incorporar documentação GoodWe autorizada, aumentar o dataset, revisar notas por mais de um avaliador e calibrar recuperação/recusa.

Equipe

Integrante	RM
Bernardo Zauza Amorim	568808
Bruno Almeida de Oliveira	572648
Gabriel Góes Nunes Pereira	571735
Guilherme Vinciguerra Carvalho	571951
Marcos Peterson Martins Pereira	573857
Matheus Jorge Santana	574166

Reprodução e fontes internas

Instalação e execução em app/README.md; protocolo e resultados em evals/relatorio_rag.md; comparação de modelos em docs/relatorio_modelos.md; composição em docs/sprint4/integrantes_rm_turma.txt.